

선행연구 조사

Claude 포렌식

▼ PART 1. Claude 제품군과 아티팩트 구성

1.1 전체 지형서

1) 대화형 (로컬 = 사본)

- claude.ai 웹
- Claude Desktop
- 모바일 앱

2) 에이전트형(로컬 = 정본)

- Claude Code
- cowork

3) 임베드형

- Chrome 확장
- Office 애드인
- IDE 확장

1.2 제품군별 선정

	제품	형태	실행 위치
1	claude.ai 웹	브라우저 SPA	서버
2	Claude Desktop	Electron 앱	서버 + 로컬(MCP)
3	Claude Code	CLI 에이전트	로컬 실행

1.3 제품별 아티팩트 구성

① claude.ai

%LOCALAPPDATA%\Google\Chrome\User Data\Default\

아티팩트	예상 내용
History	claude.ai/chat/<UUID> + 방문시각·횟수
Network\Cookies	세션 토큰, 계정·조직 ID (DPAPI 암호화)
IndexedDB\https_claude.ai_0...	대화 캐시 여부가 최대 쟁점
Local Storage\leveldb\	UI 상태, 마지막 대화 ID, 초안

Cache\Cache_Data\	대화 목록 GET 응답(제목·ID·생성시각)
Service Worker\CacheStorage\	앱 셀 자산

응답은 스트리밍(SSE) + POST이므로 **본문이 HTTP 캐시에 온전히 남을 가능성은 낮다**. 반면 대화 목록 조회는 GET일 가능성이 있어 **제목 목록 확보 가능성**이 있다.

② Claude Desktop

웹의 모든 저장소를 그대로 상속(Electron = Chromium)하고 다음이 추가된다.

아티팩트	내용
logs\main.log	앱·설정 검증 이벤트
logs\claude.ai-web.log	렌더러 이벤트
logs\mcp*.log	MCP 연결·도구 호출 이벤트
ant-did	랜덤 UUID 기기 식별자
홈 디렉터리 산출물 폴더	앱 데이터 삭제 후에도 잔존

- 경로 분기

설치 방식	데이터 경로
Store / WinGet / MSIX	%LOCALAPPDATA%\Packages\Claude_<해시>\LocalCache\Roaming\Claude\
직접 .exe	%APPDATA%\Claude\

③ Claude Code

```
C:\Users\<user>\.claude\
├─ projects\<경로치환폴더>\<session-uuid>.jsonl  ← 세션 전사 (전문)
│   └─ <session-id>\subagents\agent-*.jsonl
├─ skills\                                     ← 커스텀 스킬
├─ 설정 파일 (.claude.json 등)
└─ (프로젝트별) CLAUDE.md, memory\
```

항목	대응 평면
사용자 프롬프트·AI 응답 전문	통신
도구 호출 입력·출력	행동
확장 사고(thinking) 블록	추론
작업 디렉터리, git 상태	행동
모델 선택, 토큰 사용량	정체성
CLAUDE.md, 메모리 파일	지식

저장 시 암호화되지 않으며 OS 파일 권한이 유일한 보호다. 도구가 자격증명 파일을 읽으면 그 값이 그대로 전사에 기록된다.

▼ PART 2. 학술연구

① Conversational AI forensics: A case study on ChatGPT, Gemini, Copilot, and Claude

Cho, Park, Kim, Kim, Jeong (성균관대) | *FSI: Digital Investigation* 52, 301855 (2025)

4개 서비스 각각에 대해 획득 가능한 아티팩트, 절차, 오픈소스 도구를 제시. 기존 포렌식 연구가 대화형 AI를 주로 도구로 써온 것과 달리, 아키텍처와 데이터 아티팩트를 포렌식 관점에서 분석해 새 조사 프레임워크를 제안.

클라우드 서비스 4종을 같은 기준으로 비교하는 **연구 설계의 틀**. 구조 참고하기

무료: https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4888688

정식:

<https://www.sciencedirect.com/science/article/abs/pii/S2666281724001823>

논문한글:

[4개 대화형 ai 포렌식 한.pdf](#)

② Digital Forensic Investigation of the ChatGPT Windows Application

Kankanamge 외 | arXiv:2505.23938 (2025)

Windows 앱 대상. 범죄 시나리오 3종을 설계하고, 설치 → 프롬프트 → 앱삭제 → 내보내기 → 전원차단 순으로 단계마다 수집. RAM 덤프에서 앱 삭제 후 모두 생성 텍스트가 확인됐고, 레지스트리 흔적은 재부팅 후에도 지속됨.

실험 시나리오 설계법과 증거관리(MD5·SHA-256 이중 해시, 휘발성 등급).

<https://arxiv.org/abs/2505.23938>

③ Foundations for Agentic AI Investigations from the Forensic Analysis of OpenClaw

Gruber & Hilgert (KIT + Fraunhofer FKIE) | arXiv:2604.05589 (2026)

5개 아티팩트 평면 분류, 차분 포렌식 분석 방법론, 소프트 삭제 발견. 부속 저장소에 아티팩트의 기계 판독 가능 기술서, OpenClaw 포렌식 분석을 지원하는 파이썬 도구, DFXML 출력 형태의 분석 과정 문서가 들어 있음.

`artifact-examiner` 는 분석 결과를 활용해 포렌식 데이터를 자동으로 수집·파싱·상관하는 CLI 도구.

논문 + 코드 + 실험 로그(DFXML) + 아티팩트 명세 다 포함됨. 산출물 구성을 이대로 잡으면 좋을듯?

논문: <https://arxiv.org/abs/2604.05589>

코드: <https://github.com/jgru/forensic-analysis-of-openclaw>

논문한글:

[open claw한.pdf](#)

④ Forensic Analysis of Artifacts from Microsoft's Multi-Agent LLM Platform AutoGen

Walker 외 | ACM ARES 2024, pp. 198:1–198:9

에이전트형 도구를 대상으로 한 최초의 포렌식 분석으로, 로그·설정 파일·에이전트 통신 흔적·실행 메타데이터를 식별해 에이전트 행위와 작업 흐름을 재구성할 수 있음을 보였습니다.

Claude Code의 **서브에이전트** 구조가 AutoGen의 다중 에이전트와 유사함. 서브에이전트 세션 파일 분석 시 참고하면 좋을듯

<https://doi.org/10.1145/3664476.3670908>

▼ 사용자 행위

[Chat_LLM_User_Action_Taxonomy](#)

챗 인터페이스 사용자 행위 목록 (σ) - ChatGPT • Claude • Gemini

디지털포렌식 프로젝트 • Claude 트랙 (T3) • 2026

목적 실험 데이터 생성을 위한 사용자 행위 (σ) 전수 정의

범위 챗 인터페이스 내 행위만. 에이전트형 도구 실행•외부 서비스 연동은 제외 (캘린더 생성, 메일 발송, 파일 시스템 조작 등)

방법론 근거 행위 σ_i 가 시스템 상태 q_i 를 전이시키고, 차분 분석 δi 로 아티팩트를 분리하는 방식 (Gruber & Hilgert 2026, Kälber et al.)

서비스 표기 GPT = ChatGPT / CL = Claude / GM = Gemini / 공통 = 3종 모두

A. 설치 • 계정 생애주기

σ	행위	대상	우선
A1	기준선 q_0 (클린 상태)	-	P0
A2	브라우저 설치 및 최초 실행	공통	P0
A3	데스크톱 앱 설치 (직접 .exe)	공통	P0
A4	데스크톱 앱 설치 (MSIX / Store)	공통	P0
A5	PWA 설치	공통	P1
A6	회원가입	공통	P1
A7	로그인 (이메일•비밀번호)	공통	P0
A8	로그인 (SSO - Google / Apple)	공통	P1
A9	계정 전환	공통	P1
A10	조직 / 워크스페이스 전환	공통	P1
A11	유료 플랜 전환	공통	P2

A3 vs A4가 핵심. 설치 방식에 따라 데이터 경로가 완전히 달라지므로 반드시 두 케이스를 모두 생성한다.

B. 대화 핵심 행위 ★

σ	행위	대상	관찰 포인트
B1	새 대화 생성	공통	대화 ID 발급 시점•형식
B2	텍스트 프롬프트 전송	공통	기본 단위
B3	응답 수신 완료	공통	스트리밍 종료 시점
B4	응답 중단 (Stop)	공통	부분 응답이 남는가
B5	응답 재생성 (Regenerate)	공통	이전 응답 잔존 여부
B6	프롬프트 편집 후 재전송	공통	대화 분기 생성
B7	분기 간 이동 ()	공통	숨은 분기 복구 가능성
B8	대화 이어가기 (수일 후 재방문)	공통	장기 세션
B9	장문 대화 (50턴 이상)	공통	가상 스크롤•컴팩션 유발
B10	매우 긴 단일 프롬프트 (1만자)	공통	저장 방식 변화

- B6이 특히 중요한 이유
프롬프트를 수정하면 원본 프롬프트와 원래 받았던 응답이 화면에서는 사라지지만 데이터에는 남을 수 있다.

사용자가 본 것 데이터에 있을 수 있는 것

수정된 질문 $A' \leftarrow \text{원본 질문 } A + \text{응답 } A$

응답 A' 수정 질문 $A' + \text{응답 } A'$

“지웠다고 생각한 질문”이 복구되면 증거 가치가 매우 크다. 사용자가 의도적으로 감춘 원래 의도가 드러나기 때문이다.

C. 대화 관리 • 삭제

σ	행위	대상	관찰 포인트
C1	대화 제목 자동 생성	공통	첫 프롬프트 기반 → 주제 노출
C2	제목 수동 변경	공통	이전 제목 잔존 여부
C3	대화 고정 / 즐겨찾기	공통	
C4	대화 아카이브	GPT	삭제와 구별됨
C5	개별 대화 삭제	공통	
C6	전체 대화 일괄 삭제	공통	
C7	대화 검색	공통	검색어 잔존 여부
C8	프로젝트 / 폴더로 이동	GPT • CL	

C1 주목. 대화 제목은 첫 프롬프트에서 자동 생성되므로 제목 목록만 확보해도 대화 주제를 알 수 있다. 본문 회수 실패 시의 대안 증거원.

D. 입력 형태

σ	행위	대상	관찰 포인트
D1	문서 업로드 (PDF/DOCX)	공통	원본 파일 캐시 잔존
D2	이미지 업로드	공통	썸네일 • 원본
D3	코드 파일 업로드	공통	
D4	클립보드 이미지 붙여넣기	공통	임시 파일 생성 여부
D5	장문 붙여넣기 → 자동 첨부 변환	GPT	
D6	드래그앤드롭 업로드	공통	

σ	행위	대상	관찰 포인트
D7	음성 입력	공통	오디오 파일 잔존 여부
D8	업로드 파일 삭제	공통	캐시 잔존 여부

- D1의 가치

업로드한 파일이 브라우저 캐시나 앱 임시 폴더에 남으면, 대화 내용이 전혀 안 남아도 “무슨 문서를 다뤘는지”를 알 수 있다. 기업 기밀 유출 사건에서 결정적 증거가 된다.

E. 출력 소비

σ	행위	대상	관찰 포인트
E1	응답 복사	공통	클립보드 이력
E2	코드 블록 복사	공통	
E3	응답 파일 다운로드	공통	다운로드 폴더 + Zone.Identifier
E4	생성 이미지 저장	공통	
E5	좋아요 / 싫어요 피드백	공통	
E6	공유 링크 생성	공통	URL이 History에 기록
E7	공유 링크 해제	공통	
E8	대화 인쇄 / PDF 저장	공통	

F. 개인화 설정

σ	행위	대상	평면
F1	커스텀 지시사항 입력	공통	지식
F2	프로필 이름•직업 입력	공통	정체성
F3	메모리 기능 활성화	공통	지식
F4	메모리 항목 수동 추가	GPT • CL	지식
F5	메모리 항목 삭제	GPT • CL	
F6	응답 스타일 설정	CL	
F7	모델 전환	공통	정체성
F8	언어 설정 변경	공통	
F9	다크모드 전환	공통	Local Storage 흔적

F1•F3은 5개 평면 중 '지식' 평면에 해당한다. 커스텀 지시사항은 사용자가 AI에게 자기 정보를 직접 입력한 것이므로 신원 정보가 담길 가능성이 높다.

G. 프라이버시 행위

σ	행위	대상	비고
G1	임시 채팅 사용	GPT • CL	서비스 고유 기능
G2	브라우저 시크릿 모드	공통	
G3	학습 데이터 사용 거부 토글	공통	
G4	로그아웃	공통	핵심 시나리오
G5	브라우저 방문기록 삭제	공통	핵심 시나리오
G6	브라우저 캐시 삭제	공통	핵심 시나리오
G7	쿠키만 삭제	공통	
G8	사이트 데이터 개별 삭제	공통	
G9	브라우저 프로필 삭제	공통	
G10	앱 제거	공통	핵심 시나리오
G11	앱 제거 + 잔여 폴더 수동 삭제	공통	
G12	계정 삭제	공통	P2

H. 데이터 이동

σ	행위	대상	비고
H1	데이터 내보내기 요청	GPT	HTML + JSON
H2	Google Takeout 내보내기	GM	
H3	내보내기 파일 다운로드 • 압축해제	공통	
H4	대화 텍스트 수동 복사 → 문서 저장	공통	

- H1•H2의 연구적 가치

내보내기 결과는 서버가 보유한 정보이다. 이를 손에 쥔 상태로 로컬을 분석하면 다음이 정량화된다.

내보내기 파일 (서버 보유분) = 완전한 정답지

vs

로컬 아티팩트 (디스크 잔존분)

↓

차이 = “로컬만으로는 무엇을 알 수 없는가” ← 연구 결과

Claude는 내보내기 기능이 상대적으로 제한적이므로, GPT•GM 트랙에서 이 방법을 활용하고 결과를 공유한다.

I. 환경 • 종료 상태

σ	행위	대상	비고
I1	브라우저 정상 종료	공통	LevelDB flush 발생
I2	브라우저 강제 종료	공통	.log 에만 잔존
I3	앱 정상 종료	공통	
I4	앱 강제 종료	공통	
I5	여러 탭 동시 사용	공통	
I6	웹 → 앱 전환 (동일 계정)	공통	
I7	오프라인 상태 접속 시도	공통	Service Worker
I8	절전모드 진입	공통	hiberfil.sys
I9	재부팅	공통	

- I1 / I2 구분이 실무에서 결정적

브라우저가 실행 중이면 최신 데이터가 .log 에만 있고 .ldb 로 반영되지 않는다.

압수 현장에서 브라우저가 켜져 있음 → I2 상태

압수 전 사용자가 정상 종료함 → I1 상태

두 상태에서 확보 가능한 데이터가 다르므로 반드시 모두 실험한다.

J. 시간 경과 (수동적 σ)

σ	경과 조건	목적
J1	1시간	잔존시간 곡선
J2	24시간	잔존시간 곡선
J3	72시간	잔존시간 곡선
J4	브라우저 10회 재시작	LevelDB 컴팩션 유발
J5	앱 업데이트 발생	마이그레이션 영향

J1~J4는 “삭제 후 언제 진짜 사라지는가”를 측정하는 축이다. 결과는 조사관용 압수 골든타임 가이드가 된다.


K. 실행 계획 - 전수 촬영은 불가능하다

σ 가 약 50 개다. 각각 디스크 이미지를 뜨면 3 서비스 $\times$ 50 = 150 개 이미지가 되어 8 주에 불가능하다.

K-1. 이미지를 뜯 지점 (필수 6장)

```
q0   기준선 (클린 스냅샷)
↓ A2~A4   설치
q1   _____ 이미지
↓ A7
로그인
q2   _____ 이미지
↓ B1~B3   마커 포함 대화 10턴
↓ B6
프롬프트 편집 1회
↓ D1
문서 업로드 1건
q3   _____ 이미지   ★분기 기준점
↓ I1
정상 종료
q4   _____ 이미지
↓ I2
강제 종료 (q3에서 재시작)
q5   _____ 이미지
```

K-2. 시나리오 분기 - 반드시 q3에서 갈라진다



(4) 순차 실행 금지. 삭제 → 로그아웃 → 앱제거를 이어서 하면 어느 행위가 무엇을 지웠는지 구분할 수 없다. 매번 q3 스냅샷을 복원한 뒤 하나씩만 실행해야 시나리오 간 오염이 없다.

K-3. 나머지 σ 처리

이미지를 뜨지 말고 행위 전후로 대상 폴더만 복사해 비교한다. 속도가 수십 배 빠르다.

행위 전: 대상 폴더 복사 + 파일 해시 목록
행위 실행
행위 후: 대상 폴더 복사 + 파일 해시 목록
→ 해시 비교로 변경 파일만 추출

K-4. 반복 실행

LLM은 동일 조건에서도 동일한 흔적을 남기지 않을 수 있다(비결정성). 따라서 B · C · G 그룹은 최소 3회 반복하고 아티팩트 출현 빈도를 기록한다.

3회 중 3회 출현 → 결정적 아티팩트
3회 중 1~2회 → 비결정적 아티팩트 (별도 집계)
3회 중 0회 → 미출현 (단, 파서 재확인 후 확정)

L. 우선순위 요약

반드시 포함 (PO)

A1 기준선

A2~A4 설치 3종 (특히 MSIX vs exe)

A7 로그인

B1~B3 대화 기본

B6 프롬프트 편집 ← 흔히 누락

C5 개별 대화 삭제

D1 문서 업로드 ← 흔히 누락

E6 공유 링크 생성

F1 커스텀 지시사항

G1•G2 임시채팅•시크릿

G4 로그아웃

G5•G6 기록•캐시 삭제

G10 앱 제거

I1•I2 정상/강제 종료 ← 흔히 누락

J1~J4 시간 경과

(4) 가장 흔히 빠뜨리는 3 개

σ	왜 중요한가
B6 프롬프트 편집	화면에서 사라진 원본 질문이 데이터에 남을 수 있음
D1 문서 업로드	대화가 안 남아도 무슨 문서를 다뤘는지 알 수 있음
12 강제 종료	실제 압수 상황이며, LevelDB flush 여부가 달라짐

최소한 이 셋은 Phase 1에 반드시 포함할 것.