

로컬 LLM 아티팩트 분석

👤 작성자 한동훈(20반_7855)

1. 분석 환경

- OS : Windows 11
- Application : LM Studio
- LM Studio Version : LM Studio 0.4.21 (Build 2)
- Ollama Version : 0.32.11
- Installed Model : Google / Gemma 4 E4B

2. LM Studio 사용자 데이터 디렉터리 확인

- 경로 : `C:\Users\<사용자>\.lmstudio\`
- 확인된 항목
 - Chat History
 - 형식 : JSON
 - 위치 : `~\conversations\<session_id>.json`
 - 휘발성 : 영구적, 사용자가 수동으로 파일을 삭제할 때 까지 유지됨.
 - 확인 가능한 정보
 - 사용자 프롬프트
 - 사용자가 LLM에 실제로 입력한 질문, 명령 파악 가능
 - 사용자의 LLM 사용 목적, 수행한 작업을 파악하는데 활용
 - AI 응답
 - 사용자가 입력한 프롬프트에 대해 AI가 생성한 응답을 확인할 수 있음
 - 특정 결과가 어떠한 프롬프트에 의해 생성되었는지 확인 가능
 - 사용 모델
 - 모델 캐시의 모델 정보와 비교해 실제 대화에 사용된 모델을 식별하는데 활용
 - 대화 세션
 - 대화 세션 단위로 대화 기록을 구분할 수 있음
 - 설정 정보
 - 사용자가 특정 작업을 위해 모델의 동작 방식을 어떻게 설정했는지 분석 가능
 - Model Cache
 - 형식 : GGUF, JSON
 - 휘발성 : 지속성
 - 위치

- GGUF 가중치 파일


```
~\models\<publisher>\<repo-name>\<model_file.gguf>
```
- HUB 메타 데이터


```
~\hub\models\<publisher>\<model-name>
```
- 확인 가능한 정보
 - 모델 파일
 - 시스템에 저장된 실제 LLM의 모델파일 확인 가능
 - 모델 제공자 및 레포지토리
 - `<publisher>/<repo-name>` 디렉터리를 통해 모델의 출처정보 확인 가능
 - 사용자가 GGUF 파일의 이름을 변경하더라도 디렉터리 구조에 모델 출처 정보가 남을 수 있음
 - 모델 메타데이터
 - 모델과 관련된 메타데이터 및 매니페스트 정보를 확인할 수 있음
 - 모델 존재 여부
 - 특정 모델이 해당 시스템에 저장되어 있었는지 확인하는데 활용 가능
- Configuration (설정 프리셋)
 - 형식 : JSON
 - 휘발성 : 지속성
 - 위치
 - 커뮤니티 프리셋


```
~\hub\presets\
```
 - 사용자 프리셋


```
~\config-presets\
```
 - 임시 초안


```
~\.internal\config-presets-drafts\
```
 - 확인 가능한 정보
 - 시스템 프롬프트
 - AI에게 부여한 역할이나 기본 행동 지침 확인 가능
 - Temperature(LLM이 답변을 생성할때 얼마나 다양하고 무작위성 있게 답변을 만들지 설정)
 - 모델의 응답 생성 설정을 확인 가능
 - Context Length
 - 모델이 처리하도록 설정된 문맥 길이 관련 정보 확인
 - GPU 설정
 - 모델 실행과 관련된 GPU 사용 설정 확인 가능
- Application & Server Logs
 - 형식

- 구조화된 txt
- 실시간 텍스트 스트림
- 휘발성
 - 서버로그는 지속적이며 월별로 분할보관
 - 실시간 스트림은 사용자가 명시적으로 출력결과를 파일로 보관하여 저장하지 않으면 보존되지 않음
- 위치
 - 영구 서버 로그


```
~/.lmstudio/server-logs/YYYY-MM/
```
 - 실시간 로그


```
lms log stream
```
- 확인 가능한 정보
 - api 요청
 - LM Studio의 Local HTTP Server에 전달된 api 요청 확인
 - Endpoint
 - 어떤 기능을 요청했는지 확인 가능
 - `/v1/chat/completions` : ai에게 질문하고 답변 요청
 - `/v1/models` : 현재 사용할 수 있는 모델 정보 요청
 - Timestamp
 - api 요청 및 서버 활동이 발생한 시점을 확인 가능
 - Model Load / Unload
 - Client IP
 - 다른 장치에서 서버에 접근한 경우 클라이언트 IP정보를 확인 가능
- RAG Pipeline Cache
 - 형식
 - Binary
 - Txt
 - 휘발성
 - 반지속성, 삭제 가능한 캐시 폴더이지만 세션이 끝나도 유지되는 경우가 많음
 - 위치
 - 활성 세션


```
~\.internal\retrieval-sessions\
```
 - 벡터 청크


```
~\.internal\cached-rag-pipeline-chunks\
```
 - 추출 평문


```
~\.internal\parsed-documents-cache\
```

- 확인 가능한 정보
 - RAG 세션
 - RAG기능을 사용한 세션과 관련된 정보 확인 가능
 - 문서 청크
 - 입력 문서가 분할된 청크 데이터 확인 가능
 - 추출된 평문, 입력문서 흔적
 - PDF, DOCX 등의 입력 문서에서 추출된 텍스트가 남을 수 있음
- API Prediction History (API 예측 기록)
 - 형식
 - Binary pack
 - 휘발성
 - 지속성, packs 파일은 시간이 지남에 따라 누적됨.
 - 위치
 - `~\.internal\api-prediction-history\packs\`
 - 확인 가능한 정보
 - 수행된 모델 호출 확인
 - Python 스크립트 사용 흔적
 - cURL 요청
 - SDK 사용 흔적
 - GUI 외부 사용
- Credentials Store (자격 증명 저장소)
 - 형식
 - 키파일
 - 인코딩 데이터
 - 휘발성
 - 지속성, 사용자가 로그아웃하거나 파일을 삭제할 때 까지 유지됨.
 - 위치
 - `~\credentials\`
 - `~\..\internal\lms-key-2\`
 - 확인 가능한 정보
 - LM Studio 허브 인증 키
 - 외부 서비스 토큰
 - 인증관련 Key Material
 - 외부 레포지토리와 관련된 인증 정보 확인

- User Files

- 형식

- 원본파일형식
 - pdf
 - txt
 - docx

- 휘발성

- 지속성

- 위치

- `~\user-files\`

- 확인 가능한 정보

- 사용자 업로드 파일
 - RAG 입력 파일
 - 파일 타임스탬프(파일의 생성, 수정 시간)

분석대상	형식	저장위치	의미
Chat History	구조화된 json	~\conversations\ <session_id>.json	사용자, ai가 주고받은 질문, 답변
Model Cache	GGUF 모델 가중 치 파일 JSON	GGUF 가중치 파일 ~\models\<publisher>\<repo- name>\<model_file.gguf> HUB 메타 데이터 ~\hub\models\<publisher>\ <model-name>	다운로드하여 사용한 ai모델 파일 및 출 처 정보
Configuration	JSON	커뮤니티 프리셋 ~\hub\presets\ 사용자 프리셋 ~\config-presets\ 임시 초안 ~\.internal\config-presets-drafts\	ai의 역할 지정 및 동작 파라미터 설정 값 ai에게 특정한 역할을 부여했는지 파악
application & server logs	서버로그 : txt 실시간 스트림 : 실 시간 텍스트 출력	영구 서버 로그 ~\server-logs\YYYY-MM\ 실시간 스트림 CLI 명령 lms log stream을 통해 접 근	서버로그 : 언제 어떤 ip에서 엔드포인 트를 호출했는지 기록 실시간 스트림 : 템플릿 처리 후 ai엔진 으로 전달된 완벽한 최종 프롬프트 포착
RAG Pipeline Cache	내부 바이너리/벡 터 데이터 및 추출 된 평문 텍스트	활성 세션 ~\.internal\retrieval-sessions\ 벡터 청크 ~\.internal\cached-rag-pipeline- chunks\ 추출 평문 ~\.internal\parsed-documents- cache\	원본 파일이나 대화가 삭제되더라도 ai 가 읽었던 유출 문서, 비밀파일의 일부/ 전체 평문 텍스트 복구
API Prediction History	바이너리 pack 파 일	~\.internal\api-prediction- history\packs\	GUI 대화창에 나타나지 않는 파이썬 스 크립트, cURL 명령어 등 자동화된 대

분석대상	형식	저장위치	의미
			량 모델 사용 흔적 탐지
Credentials Store	키파일(평문/base64 인코딩)	~\credentials\ ~\..internal\lms-key-2\	저장된 비밀키/토큰을 통해 사용자의 외부 계정 명의 및 LM Studio Hub 인증 사실 식별, 인증
User Files	원본파일형식(pdf,txt,docs...)	~\user-files\	사용자가 실제 입력했던 외부문서 원본 직접 확인 가능.

3. Ollama 사용자 데이터 디렉터리 확인

- 경로 : `C:\Users\<사용자>\.ollama\`
- 확인된 항목

분석대상	형식	저장위치	의미
Model Manifest	json	~\models\manifests\registry.ollama.ai\library\ <model>\<tag>	사용자가 다운로드한 모델의 종류와 버전 확인 모델을 구성하는 각 Blob의 SHA-256해시를 통해 정확한 모델 구성, 무결성 확인
Model Blobs	바이너리 데이터	~\models\blobs\sha256-<hash>	실제 LLM 모델을 구성하는 데이터. Manifest의 SHA-256해시와 대조하여 특정 모델이 시스템에 존재했는지 확인 가능
Server Log	txt	~\logs\server.log	서버의 시작과 종료시간 모델로그 api 요청 등의 활동을 확인
CLI History	txt	~\history\	ollama run 명령을 통해 사용자가 입력한 프롬프트를 직접 확인 가능(사용자의 LLM 사용 목적 및 의도 파악) API나 외부 GUI를 통한 사용기록은 포함하지 않음
Configuration	환경변수 서비스 설정 파일	환경변수 : OLLAMA_MODELS, OLLAMA_HOST	사용자가 기본 설정과 다른 환경을 구성했는지 확인 가능. OLLAMA_MODELS : 모델의 사용자 지정 저장 위치 확인 OLLAMA_HOST : Ollama 서버의 네트워크 바인딩 설정 및 외부 접근 가능성 분석

4. 참고 자료

- a. <https://arxiv.org/html/2603.23996v1>
- b. LM Studio (<https://lmstudio.ai/docs/app>)
- c. Ollama (<https://github.com/ollama/ollama/>)